华清远见
HQYJ.COM

KNN与决策边界

韩雁泽

华清远见|元宇宙实验中心
yyzlab.com.cn

目录

CONTENTS

01. KNN算法简介

02. 决策边界

03. KNN的决策边界计算

04. 距离方案

华清远见 HQYJ.COM

华清远见元宇宙实验中心 yyzlab.com.cn

01 KNN算法简介

华清远见
HQYJ.COM
华清远见|元宇宙实验中心
yyzlab.com.cn

什么是KNN

华清远见 HQYJ.COM

定义

KNN算法是一种基于实例的学习，通过测量不同数据点之间的距离进行分类或回归分析。

原理-“近朱者赤”

基于实例的学习（instance-based learning），属于懒惰学习（lazy learning），即KNN没有显式的学习过程，也就是说没有训练阶段，它是通过测量不同数据点之间的距离进行分类或回归分析。

特点

KNN算法简单易懂，易于实现；
无需训练阶段，直接进行分类或回归；
适用于多分类问题；
对数据集的大小和维度不敏感。

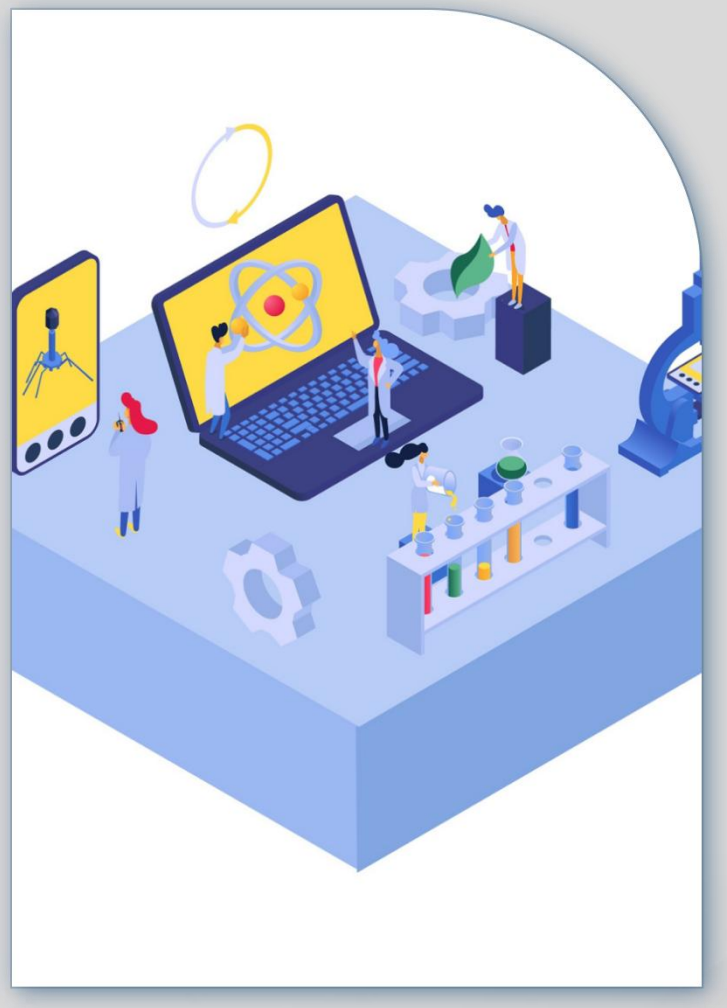

华清远见北京实验中心 jyzlab.com.cn

例子

华清远见 HQYJ.COM

案例引入：

使用KNN处理分类问题，为了便于理解，这里处理二维的数据。

例如：在某二维平面内有三种不同颜色的点：红色、蓝色、绿色，它们的颜色和它们的位置（即X、Y轴的坐标）有关系，给它们三类点画出它们各自的“房间”，采用KNN解决。

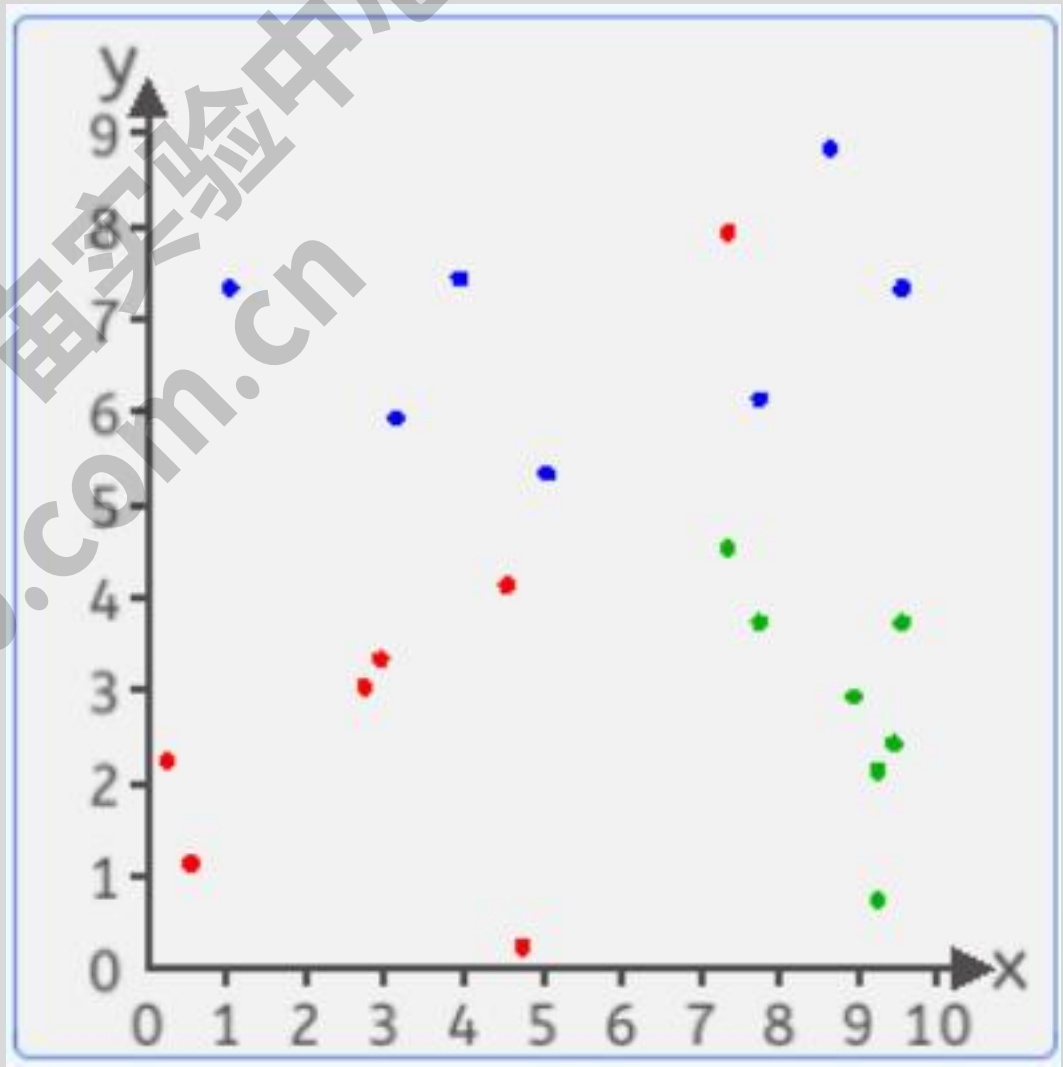

华清远见元宇宙实验中心 yyzlab.com.cn

02 决策边界

华清远见 HQYJ.COM
华清远见|元宇宙实验中心
yyzlab.com.cn

决策边界

华清远见 HQYJ.COM

定义

决策边界是分类算法中用于区分不同类别的虚拟边界，即上一章节所指出的“房间”。

边界效果

决策边界是否合理，直接影响到分类效果的好坏。

KNN与决策边界

KNN算法通过计算待分类样本与已知样本之间的距离，找到最近的k个样本，并根据这些样本的类别信息进行投票，以确定待分类样本的类别。

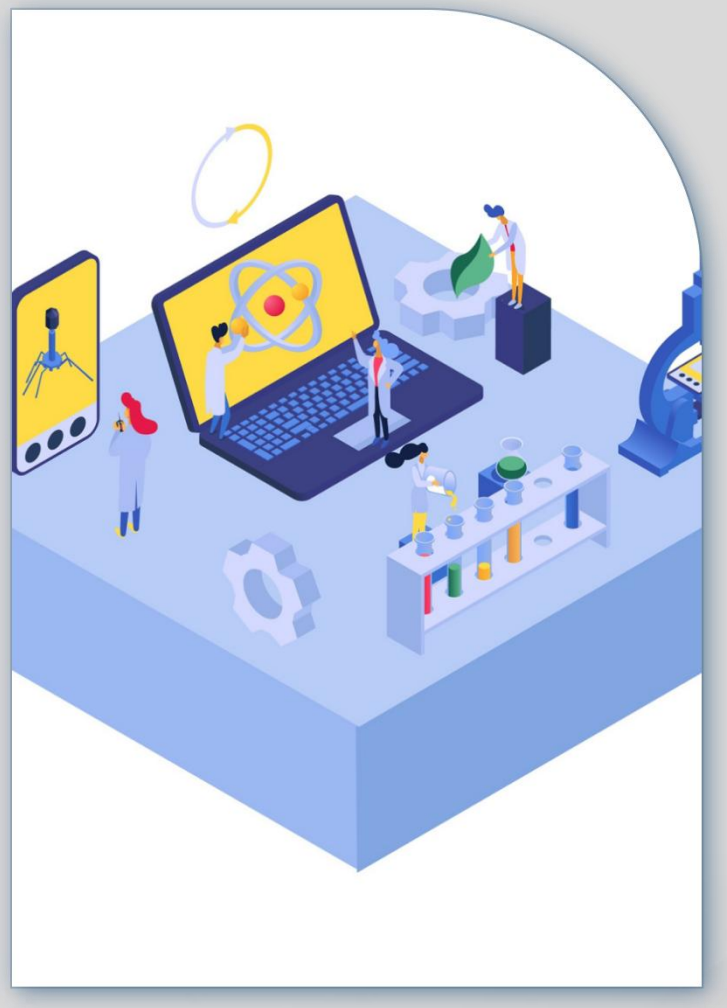

华清远见元宇宙实验中心 yyzlab.com.cn

03 KNN的决策边界计算

华清远见
HQYJ.COM
华清远见计算机实验中心
yyzlab.com.cn

计算过程

那么如何使用KNN将新的点进行分类呢？需要给KNN制定步骤：

（1）计算距离；

（2）取出距离最近的点，找到新的点与哪一类更接近，观察分类结果。

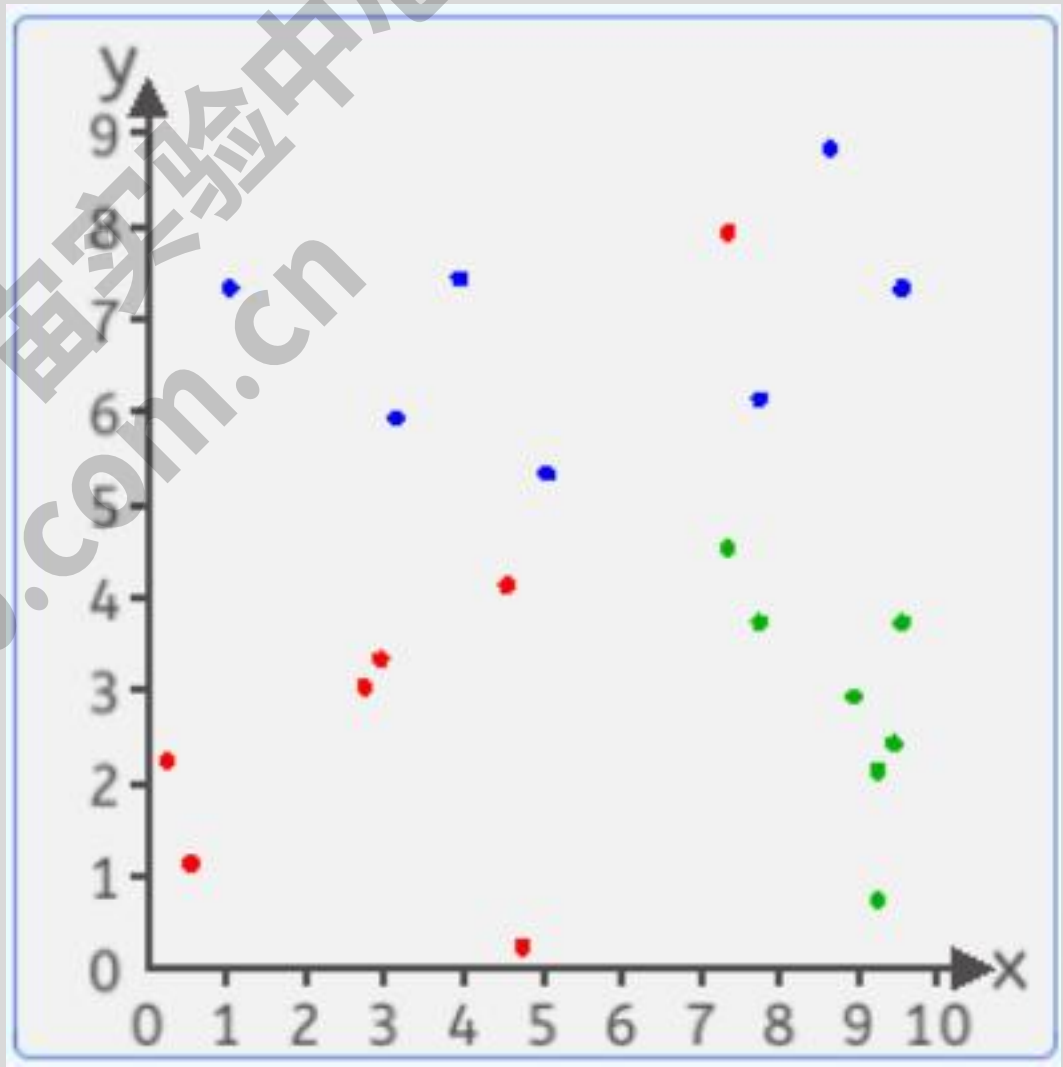

华清远见 HQYJ.COM
华清远见|元宇宙实验中心 yyzlab.com.cn

新的点是什么？

华清远见 HQYJ.COM

在预测过程中：

新的点就是某一个真实的二维坐标的点。

在绘制决策边界时：

新的点是二维坐标中所有的点（为了使其可计算，每隔距离x取一个点）。

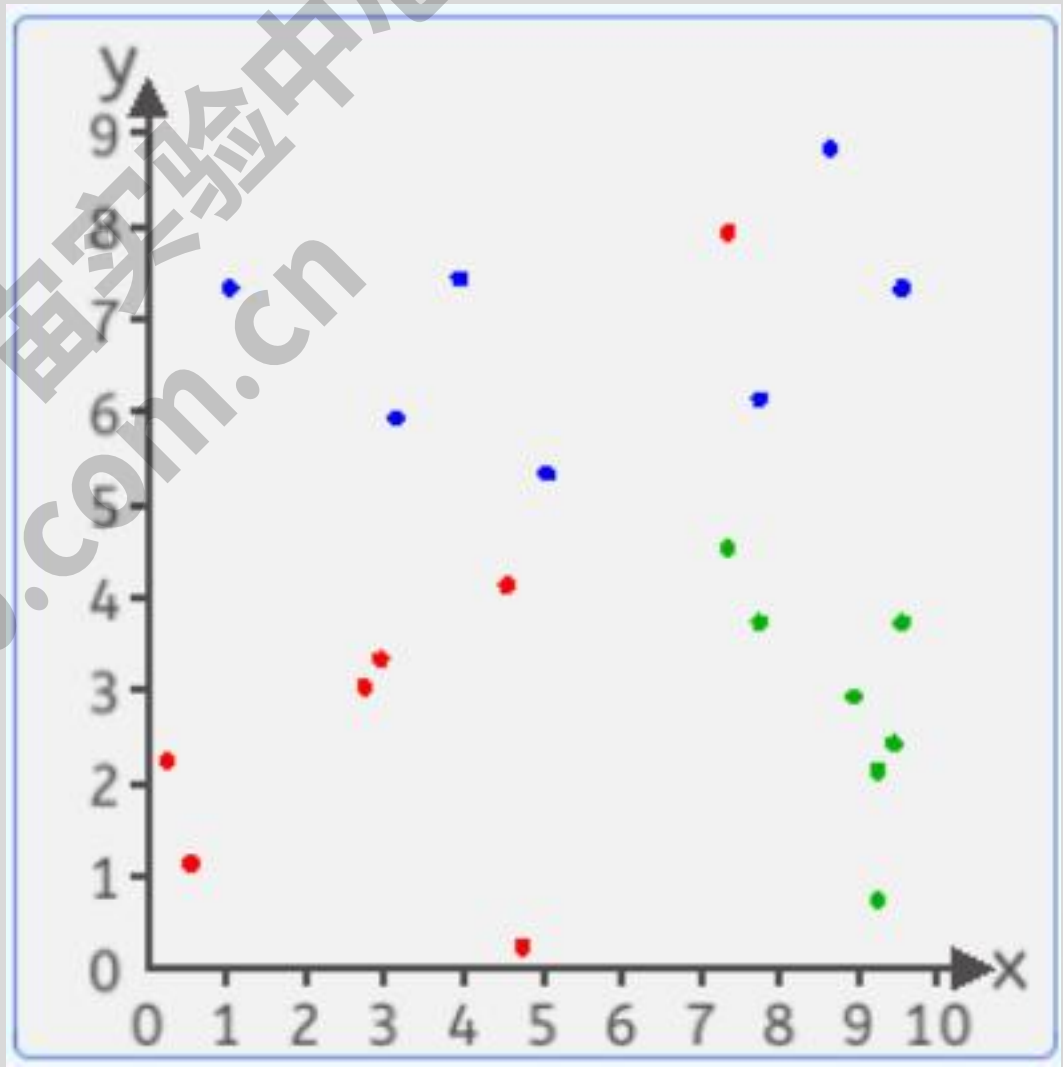

华清远见元宇宙实验中心 yyzlab.com.cn

如何更加准确的用距离分类?

华清远见 HQYJ.COM

K近邻法（K-Nearest Neighbor，KNN）：

计算新的点（测试点）到每一个已知点（标签点）的距离，并比对距离，只需要寻找最近的1个标签点作为测试点的标签就可以吗?

答案是否定的。

KNN最简单的思想是：找到与预测数据最相近的K个数据，然后对预测数据进行投票，票数最高的标签作为预测数据的标签。当k=1时，K近邻算法就变成了近邻算法。

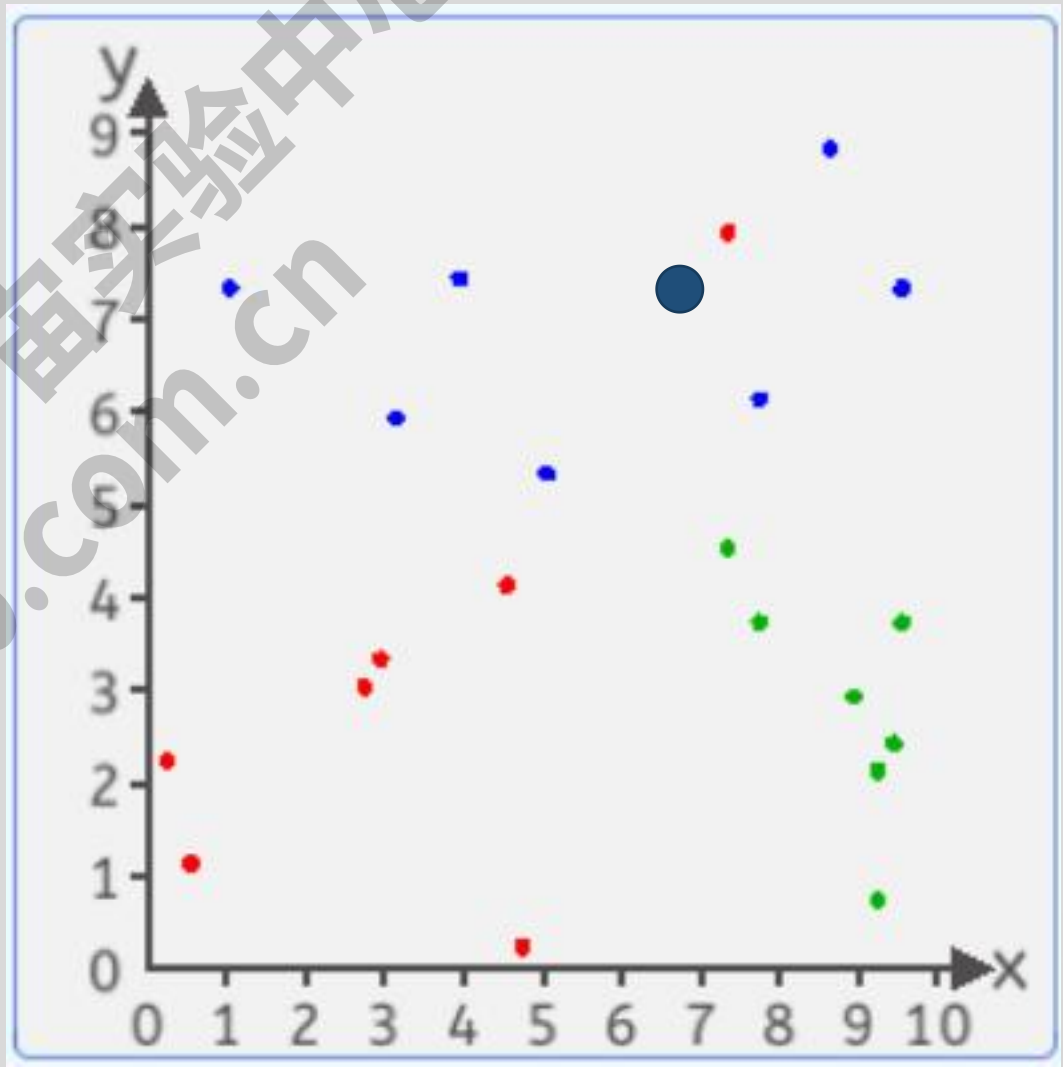

华清远见元宇宙实验中心 yyzlab.com.cn

不同的K值的决策边界

k=1

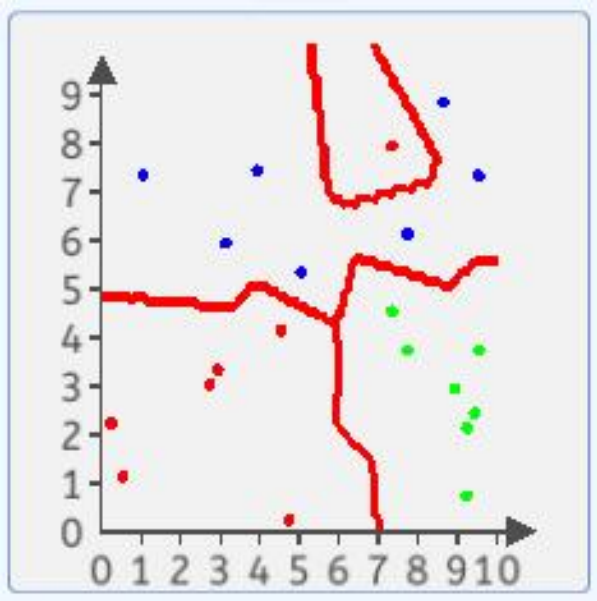

异常的数据点（蓝色中的红色点）创造出了一个非正常的预测区域（孤岛）。

k=3

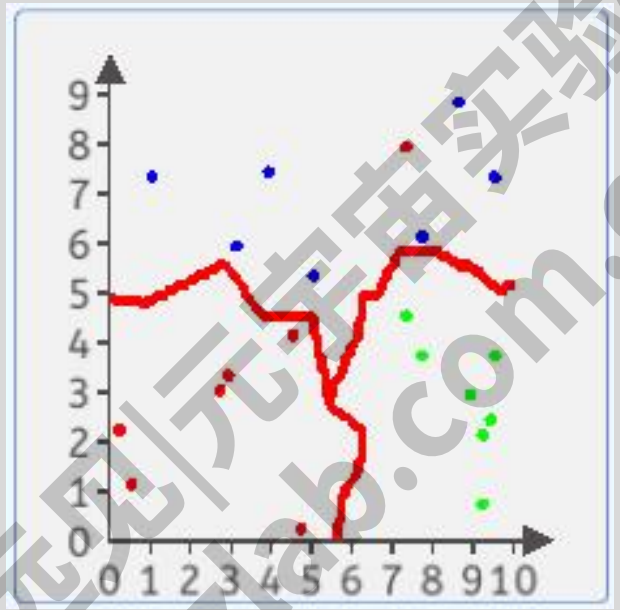

孤岛消失了，决策边界更加平滑，针对测试数据的泛化能力更好。

k=5

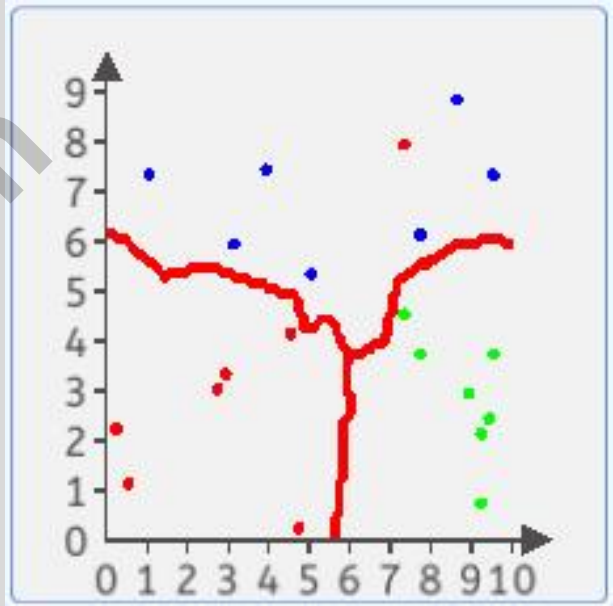

孤岛消失了，决策边界更加平滑，针对测试数据的泛化能力更好。

华清远见元宇宙实验中心
yyzlab.com.cn

结论

华清远见 HQYJ.COM

K值选择太小

优点：复杂的数据集，K值较小可能会提供更详细的决策边界，因为模型更加灵活。

缺点：容易受到局部结构的影响，模型对噪声和异常值的影响更大。

K值选择太大

优点：考虑了更多的全局信息，对于平滑的数据集，较大的K值可以提供更稳定的决策边界。

缺点：对于复杂的数据集，较大的K值可能会导致模型过于简单，无法准确捕获数据的局部特征。

K叫什么？

在KNN中，需要人为选择不同的K的不同取值，这个参数是需要人为选择的。需要人为确定的参数称为超参数（hyperparameter）。

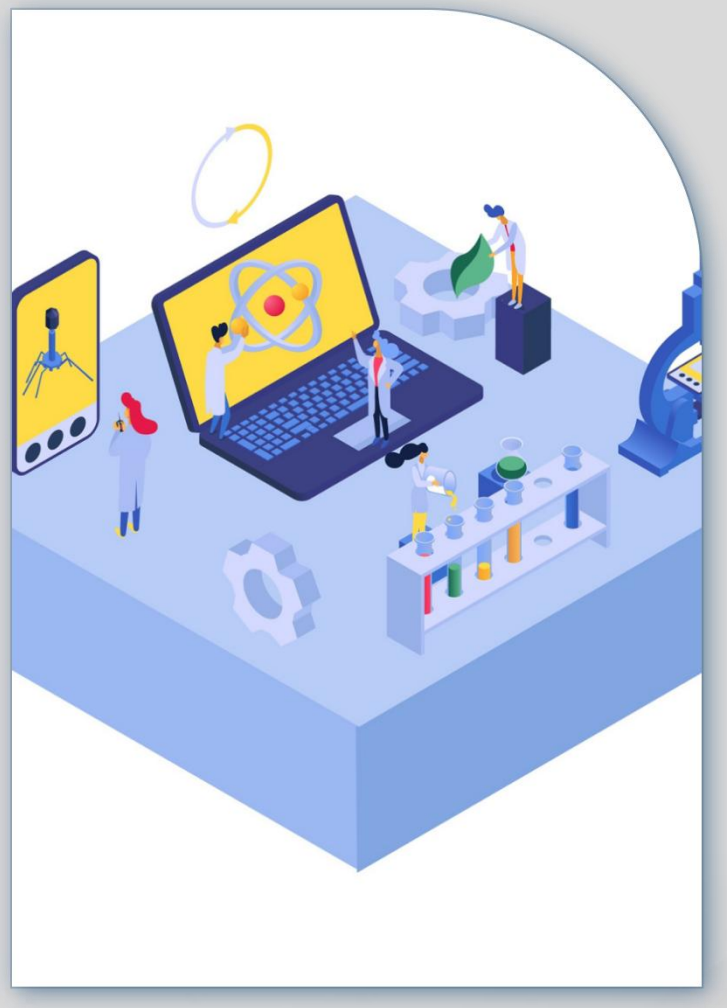

华清远见元宇宙实验中心 yyzlab.com.cn

如何选择K值 - 交叉验证

华清远见 HQYJ.COM

准备数据集

准备好包含特征和标签的数据集。

K折交叉验证

确定K的值，例如选择5或7作为K值。

划分数据集

将数据集划分为K个大小相似的子集。

循环训练和评估

使用K-1个子集作为训练集，剩余的1个子集作为测试集。
在训练集上训练KNN模型。
使用训练好的模型对测试集进行预测。
使用性能指标评估。

计算平均性能

将K次验证的性能指标取平均值，作为KNN模型的最终性能评估。

选择最佳K值

可以尝试不同的K值，并通过交叉验证选择性能最好的K值。然后选择在交叉验证中表现最佳的K值。

选定最终的K值

使用选择的最佳K值，在整个训练集上重新训练KNN模型，以获得最终的模型。

华清远见|元宇宙实验中心 yyzlab.com.cn

04 距离方案

华清远见
HQYJ.COM
华清远见|元宇宙实验中心
yyzlab.com.cn

欧式距离与曼哈顿距离

曼哈顿距离/L1距离

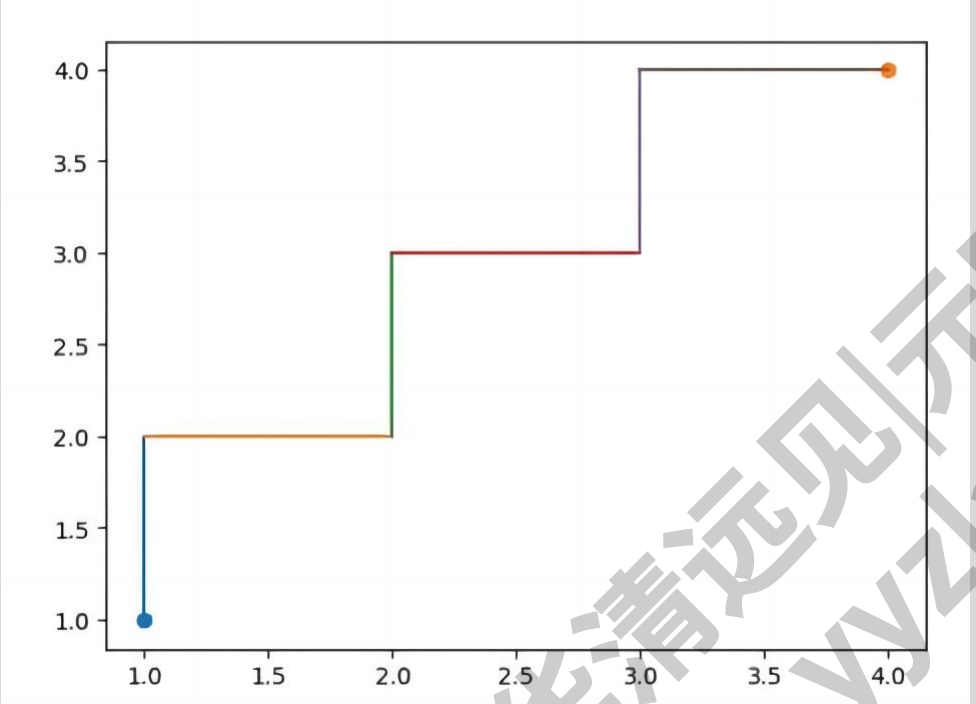

欧式距离/L2距离

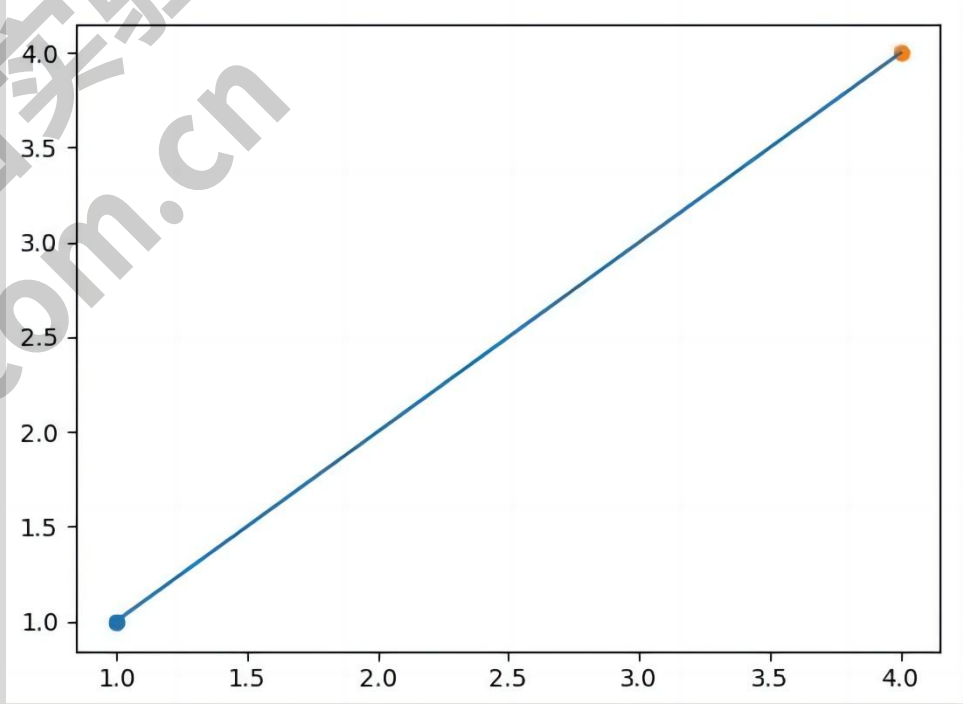

L1 距离公式为：$d_1(I_1, I_2) = \sum_{p=1}^{n} |I_1^p - I_2^p|$。

L2 距离公式为：$d_2(I_1, I_2) = \sqrt{\sum_{P=1}^{n} (I_1^P - I_2^P)^2}$。

华清远见元宇宙实验中心
yyzlab.com.cn

华清远见
HQYJ.COM

科技赋能·智引未来

技术领先
品质保障

超多干货
实时更新

海量视频
贴身学习

了解更多信息请访问：

集团官网：www.hqyj.com

创客学院网址（在线课程）：www.makeru.com.cn

研发中心网址（研发产品）：www.fsdev.com.cn

元宇宙实验中心网址（在线实验）：www.yyzlab.com.cn

华清远见元宇宙实验中心
yyzlab.com.cn